

数据掘金 ESG 智策未来

基于细粒度金融文本与市场数据的ESG投资策略优化



目 录

1.项目概述	1
1.1 研究背景与研究意义.....	1
1.1.1 ESG 投资成为主流趋势，市场规模迅猛增长.....	1
1.1.2 传统 ESG 评估体系存在显著缺陷，市场亟需动态监测工具.....	2
1.1.3 数据融合：ESG 投资策略优化的前沿与方向.....	4
1.2 应用领域场景.....	5
1.2.1 量化投资机构的策略研发与因子库增强.....	5
1.2.2 主动型资产管理公司的组合管理与产品创新.....	5
1.2.3 金融科技与数据服务商的知识赋能与解决方案升级.....	5
1.2.4 监管科技领域的市场风险监测.....	5
1.3 主要工作及创新.....	6
1.3.1 数据采集与处理.....	6
1.3.2 数据分析.....	6
1.3.3 可视化大屏设计.....	6
1.4 国内外研究现状综述.....	7
1.4.1 国外研究现状.....	7
1.4.2 国内研究现状与特色.....	8
2. 解决方案.....	11
2.1 问题界定.....	11
2.2 总体方案设计.....	11
2.3 方案功能.....	13
3. 关键技术.....	13
3.1 数据工程.....	13
3.1.1 多源数据采集与融合.....	13
3.1.2 数据预处理与特征工程.....	14
3.2 算法模型.....	15
3.2.1 基于 FinBERT 与自建词典的细粒度 ESG 文本情感分析.....	15
3.2.2 基于文本挖掘的 ESG 报告披露特征评估.....	17

3.2.3 基于 ESG 报告信息披露特征的 ESG 投资策划构建	24
3.2.4 基于机器学习的 ESG 投资策略优化.....	32
3.3 数据可视化大屏设计.....	38
3.3.1 项目介绍.....	38
3.3.2 可视化系统设计.....	39
3.3.3 可视化系统界面介绍.....	41
3.4 实现过程.....	45
4. 应用价值.....	46
4.1 经济效益分析	46
4.1.1 提升投资组合的绝对收益与风险调整后收益	46
4.1.2 增强风险管理与回撤控制.....	46
4.1.3 优化投资决策流程与效率.....	47
4.2 社会价值分析.....	47
4.2.1 精准引导资本流向，赋能实体经济转型.....	47
4.2.2 提升市场信息效率，强化社会监督	47
4.2.3 推动 ESG 理念的深化与普及	48
5. 系统优化与展望.....	48
5.1 当前局限性.....	48
5.2 未来展望.....	49
参考文献.....	50

1.项目概述

1.1 研究背景与研究意义

1.1.1ESG 投资成为主流趋势，市场规模迅猛增长

近年来，环境、社会和治理（ESG）因素已从边缘化的伦理投资理念，迅速演进为影响全球资本配置的核心维度。



图 1-1 ESG 概念图

根据彭博社的预测，到 2025 年，全球 ESG 资产规模预计将超过 53 万亿美元，展现出巨大的市场影响力。另据数据显示，截至 2025 年第二季度，全球 ESG 基金的市场总规模已突破 3.5 万亿美元，单季度增长约 10%，其规模甚至首次超越了国内非货币基金。中国市场方面，在“双碳”目标和国家政策的推动下，ESG 实践快速落地。2024 年，深交所、上交所和北交所联合发布《上市公司可持续发展报告指引》，标志着 A 股正式进入 ESG 信息披露的强制化阶段。这一背景下，如何精准、高效地识别和评估企业的真实 ESG 表现，成为学术界和实务界共同关注的焦点。




图 1-2 全球 ESG 投资规模柱状图

本研究的意义在于，通过开发基于金融文本与市场数据的 ESG 投资策略优化方法，为投资者提供更加精准、动态的企业 ESG 表现评估工具，有助于推动 ESG 投资从概念走向实践，促进资本向真正具备可持续发展能力的企业配置，服务于国家“双碳”目标和高质量发展战略。

1.1.2 传统 ESG 评估体系存在显著缺陷，市场亟需动态监测工具

尽管 ESG 投资理念日益成为全球金融市场的主流趋势，但其投资策略所依赖的传统第三方 ESG 评级体系存在固有缺陷，严重制约了投资策略的有效性，这主要体现在信息滞后性、易受“漂绿”误导以及评级结果不一致三个方面。

表 1-1 ESG 主要内容与缺陷表

方面	主要内容	缺陷
环境 (E)	含碳排放、能源效率、废弃物回收等指标，评估企业生态影响与环境风险应对能力	1.信息滞后：难实时捕捉突发污染、供应链环境风险，易错失应对窗口； 2.易“漂绿”误导：企业夸大减排成效，缺第三方监测，难验证实际效果； 3.评级差异：机构权重不同，评级偏差大
社会 (S)	含员工权益、供应链劳工标准、消费者保护等指标，评估企业社会贡献与责任履行	1.信息滞后：难预警供应链劳工纠纷、隐私泄露，易引发声誉风险； 2.易“漂绿”误导：企业宣称保障权益，却存职场歧视等问题； 3.评级差异：机构对指标优先级认知不同，结果差异显著
治理 (G)	含董事会独立性、反腐败、信息披露等指标，评估企业治理规范性与决策公平性	1.信息滞后：难实时发现高管贪腐、关联交易等隐蔽问题； 2.易“漂绿”误导：企业制度完善但执行流于形式，缺落地效果核查； 3.评级差异：机构对指标权重、标准设定不同，治理效果难量化

首先，传统评级主要基于企业年报等历史信息，通常按季度或年度更新，难以实时捕捉突发 ESG 事件所带来的风险。例如，2025 年 9 月，户外品牌始祖鸟在喜马拉雅山脉进行的“艺术烟花”项目引发巨大环保争议，此举被指违背了户外品牌应恪守的“无痕山林”核心价值观，导致其母公司安踏体育在港股市场单日市值蒸发显著，股价一度大跌超过 7%。其次，传统评级体系易受企业“漂绿”行为误导，许多企业的 ESG 承诺仅停留在报告层面，与实际行动严重脱节。再者，不同 ESG 评级机构在指标体系、权重分配以及对 ESG 概念本身的认知上存在显著差异，这导致对同一家企业的评级结果可能大相径庭，降低了评级的可靠性与可比性。

表 1-2 不同 ESG 评级机构评分对比

评级机构	数据来源	指标体系	评级设置	更新频率
<i>Bloomberg</i>	1.上市公司官网、公告、可持续发展报告等 2.公司直接填报	3 个维度 120 个指标	0-100	年度更新
<i>FTSERussell</i>	1.上市公司官网、公告、可持续发展报告等 2.公司直接填报 3.新闻舆情	3 个维度 14 个议题	0-5	月度更新
<i>MSCI</i>	1.上市公司官网、公告、可持续发展报告等 2.公司直接填报 3.新闻舆情 4.行业协会 5.企业沟通渠道	3 个维度 10 个议题	共 7 级，由低到高为：CCC、B、BB、BBB、A、AA、AAA	年度更新
<i>Refinitiv</i>	1.上市公司官网、公告、可持续发展报告等 2.公司直接填报 3.新闻舆情 4.行业协会 5.企业沟通渠道	3 个维度 10 个议题 500 余项数据点	共 12 级，由低到高为：D-、D、D+、C-、C、C+、B-、B、B+、A-、A、A+	周度更新
<i>RepRiskAG</i>	1.监管部门 2.新闻舆情 3.行业协会	3 个维度 28 个议题 73 个热点话题	共 10 级，风险由高到低为：D、C、CC、CCC、B、BB、BBB、A、AA、AAA	月度更新
商道融绿	1.上市公司官网、公告、可持续发展报告等 2.新闻舆情	3 个维度 14 个议题 200+数据点	共 10 级，由低到高为：D、C-、C、C+、B-、B、B+、A-、A、A+	年度更新
润灵环球	1.上市公司官网、公告、可持续发展报告等 2.监管部门 3.新闻舆情	3 个维度 26 个议题 100+指标	共 7 级，由低到高为：CCC、B、BB、BBB、A、AA、AAA	季度更新
华证	1.上市公司官网、公告、可持续发展报告等 2.监管部门 3.新闻舆情	3 个维度 14 个议题 26 个指标 130+数据点	共 9 级，由低到高为：C、CC、CCC、B、BB、BBB、A、AA、AAA	季度更新
<i>CASVI</i>	1.上市公司官网、公告、可持续发展报告等 2.监管部门	3 个维度 9 个议题 27 个指标	共 10 级，由低到高为：D、C、CC、CCC、B、BB、BBB、A、AA、AAA	季度更新

万得(Wind)	1.上市公司官网、公告、可持续发展报告等 2.监管部门 3.新闻舆情	3 个维度 27 个议题 300+数据点	共 7 级，由低到高为：C、CC、CCC、B、BB、BBB、A、AA、AAA	月度更新
妙盈科技	1.上市公司官网、公告、可持续发展报告等 2.监管部门 3.新闻舆情	3 个维度 19 个议题 700+指标 1000+数据点	共 12 级，由低到高为：D、DD、DDD、C、CC、CCC、B、BB、BBB、A、AA、AAA	月度更新
中证	1.上市公司官网、公告、可持续发展报告等 2.监管部门 3.新闻舆情 4.上市公司绿色收入、隐含违约率等中证特色信息	3 个维度 14 个议题 22 个指标 100+数据点	共 10 级，由低到高为：C、CC、CCC、B、BB、BBB、A、AA、AAA	月度更新

在此背景下，本研究具有重要的理论意义和实践价值。在理论层面，本研究通过探索金融文本与市场数据的融合机制，有助于深化对 ESG 信息定价效率的理解，丰富 ESG 投资理论体系。在实践层面，本研究开发的动态监测工具能够帮助投资者及时识别 ESG 风险，提升投资决策的前瞻性和准确性，同时通过对企业 ESG 实践的真实评估，形成有效的市场监督机制，抑制“漂绿”行为，推动 ESG 投资的健康发展。

1.1.3 数据融合：ESG 投资策略优化的前沿与方向

传统 ESG 评级的局限性，促使业界将目光转向更具时效性的另类数据。其中，基于金融文本的 ESG 信号因其能动态反映市场情绪和潜在风险，而受到广泛关注。




图 1-3 A 股上市公司 ESG 报告发布数量统计图

当前的研究前沿与核心挑战在于如何将这些新兴的文本衍生信号与传统的市场数据进行系统性的有效整合。本研究的意义正是在于直面这一“策略优化”阶段的核心任务。理论层面，旨在通过探索文本信号与市场数据的非线性融合机制，深化对信息如何被市场动态定价的理解，丰富多因子资产定价理论在 ESG 领域的应用。实践层面，本研究致力于通过先进的组合构建模型、动态权重配置或风险预算方法，解决文本信号与市场数据的深度融合问题，其成果将直接转化为构建新一代投资策略的关键技术支撑。

1.2 应用领域场景

本研究提出的“基于多模态 ESG 因子集成学习与强化学习动态策略的优化方法”，为解决当前 ESG 投资策略在时效性、自适应性和绩效可持续性方面的挑战提供了一套创新的方法论工具。该方法论在以下核心金融场景中具有明确的应用价值：

1.2.1 量化投资机构的策略研发与因子库增强

对于专注于寻找市场阿尔法的量化对冲基金与券商自营部门，本方法论能直接嵌入其现有的策略研发流程。多模态 ESG 因子集成学习模型可用于构建高质量的复合 ESG 信号，显著优于单一数据源的信号，从而丰富其阿尔法因子库。更重要的是，基于强化学习的动态策略框架能够自动学习在不同市场环境下如何最优地配置 ESG 因子与其他传统因子的权重，实现策略的自适应调整，替代依赖人工经验的参数调优，提升策略的稳健性与生命周期。

1.2.2 主动型资产管理公司的组合管理与产品创新

对于进行主动投资的公募基金、保险资管等机构，本方法论可应用于提升组合管理的精细度。基金经理可利用动态集成后的 ESG 信号，更敏锐地识别持仓组合中潜在的 ESG 风险或机遇，做出前瞻性的调仓决策。在产品端，该方法论为设计并回测“动态智能 ESG”主题基金提供了完整的技术蓝图，使得新产品能够宣称其内核具备根据市场状态自动优化的能力，形成独特的市场竞争力。

1.2.3 金融科技与数据服务商的知识赋能与解决方案升级

金融科技公司及数据供应商可将本方法论的核心算法封装为更高阶的解决方案。例如，不再仅仅提供原始的 ESG 舆情数据，而是提供经过集成学习优化后的“智能 ESG 评分”或甚至提供基于强化学习的策略配置建议作为增值服务。这将帮助其客户（尤其是中小型机构）跨越复杂模型构建的技术门槛，实现从“数据”到“智能”的升级，巩固其在价值链中的优势地位。

1.2.4 监管科技领域的市场风险监测

对于监管机构而言，本方法论中的多模态信息融合技术可用于构建更强大的市场风险监测工具。通过集成来自新闻、公告、社交媒体等多维度文本信息，实

现对全市场 ESG 相关风险舆情的宏观、实时感知，有助于更早地识别出区域性或行业性的风险聚集点，为穿透式监管提供数据驱动的决策支持。

1.3 主要工作及创新

本项目围绕“基于细粒度金融文本与市场数据的 ESG 投资策略优化”这一核心主题，开展了系统性的研究工作，主要工作内容涵盖数据采集与处理、多维度数据分析、算法模型构建及系统实现四个层面，并在方法论和技术应用上实现了多项创新突破。

1.3.1 数据采集与处理

选定主题“ESG 投资策略分析”，在 Wind 金融数据库、巨潮资讯网、上市公司披露平台等权威数据源进行多源数据采集，对获取的 ESG 报告、市场数据、舆情信息进行深度预处理，包括数据清洗、格式标准化、特征提取等。采集的原始数据涵盖 2017-2024 年 A 股上市公司发布的 ESG 报告、社会责任报告及可持续发展报告，共计 11971 份 PDF 格式文档，同时整合 WindAPI 提供的金融市场数据和社交媒体舆情信息。在数据预处理环节，创新性地开发了针对金融文本的专业处理流程，解决了 txt 解析、表格提取、中英文混排等技术难题。通过数据清洗、异常值处理和数据标准化，构建了统一的 ESG 研究数据库，为后续分析提供高质量的数据支持。处理过程包括文本净化、编码统一、分词处理，以及特征工程提取漂绿度、实据性、全面性和可读性等关键指标。

1.3.2 数据分析

主要分为情感分析、趋势分析、影响力分析三个部分。在情感分析中，使用基于 FinBERT 与自建词典的细粒度 ESG 文本情感分析方法，相较于传统深度学习方法，其运作更为高效、便捷，用算法实现自动化打标签代替人工。自建词典包含 490 个 ESG 专业词汇，覆盖环境、社会和治理三个维度，通过 TF-IDF 算法和语义分析量化企业 ESG 表述的积极性。在趋势分析环节，结合情感分析得到的数据结果，判断事件在投资者心中的正负向，正向指标越高，则表明企业 ESG 发展趋势向好，无需采取风险控制措施。采用时间序列模型分析 ESG 评分变化趋势，预测企业未来绩效，并通过回归分析验证 ESG 特征与长期市场价值和短期盈利能力的关联性。在影响力分析环节，基于多模态 ESG 因子集成学习模型，构建用户活跃度、互动质量的关系网络来综合评估用户影响力。通过因子贡献度分析，展示关键因子如何影响整个投资策略，并使用 CatBoost 等机器学习算法评估因子重要性。

1.3.3 可视化大屏设计

设计系统界面分布，搭建前端框架，将前期分析得到数据结果进行可视化处理。系统采用 Vue.js 框架结合 ECharts 组件库，构建交互式监控大屏，支持策略回测分析、绩效评估、实时监控等功能。通过直观的图表展示投资组合表现、因

1.4 国内外研究现状综述

年份	国外发文量	国内发文量
2012	15	0
2013	25	0
2014	35	0
2015	45	0
2016	65	0
2017	100	5
2018	140	5
2019	180	5
2020	195	5
2021	215	15
2022	240	35
2023	270	55

1.4.1 国外研究现状

7

第一阶段，研究的重心在于奠定理论基础。此时期的学术工作主要致力于确立 ESG 因素与企业财务绩效及估值之间的内在联系。学者们通过构建系统的 ESG 评价指标体系并进行实证检验，初步验证了良好的 ESG 表现能够降低企业特定风险、提升长期价值的核心假设。这一阶段以传统的计量经济学分析为主，为后续引入更先进的分析技术奠定了必要的理论基础。

进入第二阶段，研究范式开始向方法论创新转移。随着自然语言处理等计算社会科学方法的兴起，研究者开始探索将文本分析技术应用于 ESG 研究领域。这一时期的标志性进展包括：专门针对金融语境的情感分析工具的开发、ESG 相关专业词典库的建立，以及从海量非结构化文本中自动识别和提取 ESG 信息的技术路径的探索。这些工作为 ESG 研究提供了全新的数据维度和方法论支撑。

近年来，研究进入了以多源数据融合与策略深度优化为特征的第三阶段。当前的研究前沿不再满足于孤立地使用文本信号，而是聚焦于如何将其与传统的市场数据、财务数据进行有效整合。这一趋势具体体现在：利用机器学习技术对文本信息进行更深层次的语义挖掘；通过构建增强型多因子模型来探究文本因子与传统因子的协同效应；并开始尝试应用强化学习等动态优化方法，使投资策略具备根据市场环境自适应调整的能力，从而推动 ESG 投资策略向智能化、精细化方向发展。

1.4.2 国内研究现状与特色




图 1-6 中文文献关键词共现图

基于金融文本与市场数据的 ESG 投资策略研究在国内呈现出快速发展的态势，其研究路径具有鲜明的中国特色，主要体现在政策导向、方法创新和实践应用三个层面。




图 1-7 中国 ESG 实践发展阶段

（一）政策导向下的理论体系特色化构建

国内 ESG 研究紧密围绕国家发展战略，形成了独具特色的理论框架。在“双碳”目标和高质量发展战略引领下，研究者将 ESG 理念深度融入国家治理体系。具体而言，ESG 的“绿色”维度与生态文明建设理论相衔接，“社会”维度与共同富裕目标相呼应，“治理”维度与现代企业制度建设要求相统一。

2024 年三大交易所联合发布的《上市公司可持续发展报告指引》，为 ESG 研究提供了制度保障；在 2025 年 ESG 金融改革与绿色金融创新论坛上，专家强调 ESG 发展需要与“双碳”目标相匹配，凸显了政策导向的研究特色，进一步验证了这一趋势。



图 1-8 上市公司可持续发展报告指引发文

（二）方法创新与技术突破的双轮驱动

在方法论层面，国内研究开创了具有本土特色的分析路径。最具代表性的是政策文本的量化分析方法的建立。研究者通过文本挖掘技术对政府工作报告、“五年规划”等重要政策文件进行系统分析，构建政策影响力指数和传导机制模型。

在技术应用层面，国内研究展现出强大的本地化创新能力。针对中文语言特点和信息披露特征，研究者开发了专业的分词算法和语义分析模型。平安集团建立“AI-ESG”智能管理平台，该平台通过AI技术处理海量数据，既对接国际标准，又充分考虑中国特色指标，实现了ESG评估的智能化和标准化。

（三）实践应用与服务实体经济的价值导向

在实践应用层面，国内研究始终坚持服务实体经济的鲜明导向。这一特点具体体现在三个方面：首先，与产业升级紧密结合，开发针对战略性新兴产业的ESG评估工具。特别是在转型金融领域，建立科学的评估体系引导金融资源支持传统行业绿色转型。其次，考虑区域发展不平衡的现实，开展差异化探索。如海南自由贸易港构建与其低碳岛定位相适应的ESG评级体系，体现因地制宜的特色。最后，创新投资者教育方式，工银瑞信等机构通过新媒体平台制作生动内容，推动ESG投资理念的大众化传播。

表 1-3 可持续发展报告议题索引表

维度	议题	对应条款
环境	应对气候变化	第二十一条至第二十八条
	污染物排放	第三十条
	废弃物处理	第三十一条
	生态系统和生物多样性保护	第三十二条
	环境合规管理	第三十三条
	能源利用	第三十五条
	水资源利用	第三十六条
	循环经济	第三十七条
社会	乡村振兴	第三十九条
	社会贡献	第四十条
	创新驱动	第四十二条
	科技伦理	第四十三条
	供应链安全	第四十五条
	平等对待中小企业	第四十六条
	产品和服务安全与质量	第四十七条

可持续发展	数据安全与客户隐私保护	第四十八条
	员工	第五十条
	尽职调查	第五十二条
	利益相关方沟通	第五十三条
	反商业贿赂及反贪污	第五十五条
	反不正当竞争	第五十六条

2. 解决方案

2.1 问题界定

当前 ESG 投资领域面临的核心挑战在于传统评估方法的局限性。尽管 ESG 投资理念日益受到重视,但现有评估体系主要依赖第三方评级机构提供的标准化评分,这种方法存在信息滞后、评级标准不统一、难以识别“漂绿”行为等固有缺陷。企业通过精心设计的 ESG 报告展示其可持续发展形象,但报告内容与实际绩效之间往往存在显著差异,而传统评估方法难以有效识别这种差异。

另一方面,海量的非结构化文本数据未能得到充分挖掘和有效利用。上市公司发布的 ESG 报告、社会责任公告以及网络舆情中蕴含着丰富的企业可持续发展信息,但这些文本数据的价值尚未通过系统化的分析方法转化为投资决策的有力支撑。投资者需要更加细致、前瞻的评估工具来识别企业的真实 ESG 表现,而非仅仅依赖可能滞后的评级分数。

此外,现有 ESG 投资策略往往将 ESG 因素作为简单的筛选条件或权重调整因子,缺乏将文本信息与传统量化模型深度融合的智能化框架。这种简单的整合方式难以充分发挥 ESG 信息的预测价值,也无法适应复杂多变的市场环境。系统需要解决从多源异构数据采集、文本特征提取、因子有效性验证到投资策略生成与优化的全流程技术挑战,实现对 ESG 文本信息的深度价值挖掘和投资应用转化。

本系统旨在构建一个基于细粒度金融文本与市场数据的 ESG 投资策略优化平台,通过创新性的文本挖掘技术和量化分析方法,突破传统 ESG 投资的局限性,为投资者提供更加准确、及时和有效的决策支持工具。

2.2 总体方案设计

本系统采用分层架构设计,构建了一个覆盖数据采集、处理、分析、建模、策略生成与可视化的端到端 ESG 智能投资支持平台。总体架构分为数据层、业务层和展示层三个核心组成部分,通过模块化设计确保系统的高效性、可扩展性和可维护性。下图为本文整体技术框架图:




图 2-1 整体技术框架

数据层作为系统的基础设施，负责多源异构数据的统一采集、清洗、存储与管理。该层整合了上市公司 ESG 报告、Wind 金融数据库、市场行情数据、舆情信息等多维度数据源，构建了完整的 ESG 投资研究数据库。特别针对 ESG 报告的 PDF 格式解析、文本提取和编码转换建立了标准化的处理流程，为上层分析提供高质量的数据支持。

业务层是系统的智能核心，包含 ESG 文本分析引擎、多因子模型和策略生成三大模块。ESG 文本分析引擎基于自然语言处理技术，创新性地提取漂绿度、实据性、全面性和可读性四大特征指标，通过构建专用金融词典和微调预训练模型实现文本的深度挖掘。多因子模型将文本特征与传统价量因子、基本面因子融合，采用梯度提升树等机器学习算法构建预测模型。策略生成模块则基于预测结果，结合组合优化算法输出动态投资组合建议，并通过强化学习框架实现策略的自适应优化。

展示层提供交互式可视化界面，采用 Vue.js 框架结合 ECharts 组件库构建综合监控大屏。该层支持策略回测分析、绩效归因、实时监控和文档溯源等功能，通过直观的图表展示投资组合表现、因子分析结果和风险指标，为用户提供全面的决策支持。系统采用前后端分离架构，后端基于 SpringBoot 框架实现业务逻辑处理，确保系统的高效稳定运行。

整个方案通过数据驱动的方法，实现了从非结构化文本数据到可执行投资策略的完整转化流程，为 ESG 投资提供了科学、系统的解决方案。该设计不仅解决了传统 ESG 评级的信息滞后问题，还通过文本挖掘技术揭示了企业 ESG 披露的深层次信息，为投资决策提供了全新的视角和方法论支持。

2.3 方案功能

本系统具备完整的 ESG 投资分析功能体系，涵盖从数据采集到投资决策的全流程支持。数据管理功能支持多源数据的自动采集、清洗和存储，通过建立统一的数据标准和治理流程，确保 ESG 报告、市场数据、舆情信息等异构数据的高质量整合。系统提供数据质量监控和异常检测机制，能够自动识别数据缺失、格式不一致等问题，并生成数据质量报告，为后续分析提供可靠的数据基础。

文本分析功能实现 ESG 报告的智能解析，包括关键词提取、情感分析、特征量化等核心能力。特别是通过创新的漂绿识别算法，系统能够评估企业 ESG 披露的真实性，检测“说多做少”的漂绿行为。该功能基于自然语言处理技术，构建了专门的金融领域词典和语义分析模型，能够从非结构化文本中提取漂绿度、实据性、全面性和可读性四大特征指标，为投资决策提供深入的文本洞察。

投资研究功能提供完整的量化分析工具链，包括因子测试、策略回测和绩效分析三大模块。因子测试模块支持用户验证文本因子与传统因子的有效性，通过统计检验和经济学意义分析评估因子的预测能力。策略回测模块提供灵活的参数配置界面，支持用户自定义投资策略和优化目标，系统会自动执行历史回测并生成详细的绩效报告。绩效分析模块则从多个维度评估策略表现，包括收益风险比、最大回撤、信息比率等关键指标，并提供归因分析揭示收益来源。

风险监控功能实时跟踪 ESG 相关舆情变化和市场动态，建立多层次预警机制。系统通过设置阈值规则和机器学习算法，自动识别潜在的投资风险，并及时向用户发送预警通知。同时，系统支持压力测试和情景分析，帮助用户评估投资组合在不同市场环境下的抗风险能力，为风险管理决策提供数据支持。

可视化展示功能通过交互式仪表盘呈现分析结果，采用热力图、趋势图、雷达图等多种可视化形式，直观展示 ESG 评分分布、策略绩效表现和风险指标。系统支持多维度数据下钻和对比分析，用户可以便捷地进行跨行业比较、时间序列分析和基准对比。此外，系统还提供报告自动生成功能，能够根据用户需求定制化输出专业分析报告，大幅提升投资研究效率。

整个系统通过模块化的功能设计，实现了 ESG 投资从数据到决策的闭环管理，为机构投资者提供了一套完整、科学的 ESG 投资解决方案。

3.关键技术

3.1 数据工程

3.1.1 多源数据采集与融合

本项目的数据采集工作面临多源异构数据整合的复杂挑战，涉及不同类型、不同格式的数据源整合。系统通过构建统一的数据采集与融合框架，实现了对 ESG 相关多源数据的系统性整合。

在数据采集层面，系统主要整合了四大类数据源：首先是上市公司 ESG 报告数据，通过爬虫技术从巨潮资讯网、上海证券交易所、深圳证券交易所等官方信息披露平台批量获取 2017-2024 年 A 股上市公司发布的 ESG 报告、社会责任报告及可持续发展报告，共计 11145 份 PDF 格式文档。这些文档在格式、内容结构、披露标准等方面存在显著差异，增加了数据处理的复杂度。其次是金融市场数据，通过 WindAPI 接口获取上市公司 ESG 评分、财务指标、股价行情等结构化数据，涵盖资产负债表、利润表、现金流量表等核心财务信息。第三类是网络舆情数据，从微博、抖音、新闻网站等渠道采集与 ESG 相关的舆情信息，包括文本内容、发布时间、转发评论量等字段。最后是基础信息数据，包括上市公司基本信息、行业分类、地区分布等元数据。

数据融合过程中面临的主要技术挑战包括数据格式不统一、采集频率差异、数据质量参差不齐等问题。针对 PDF 格式的 ESG 报告，系统采用 *PDFMiner* 和 *PyPDF2* 等工具进行文本提取，处理过程中需要解决中英文混排、表格解析、图片文字识别等复杂情况。对于网络舆情数据，需要突破平台反爬机制，采用分布式爬虫架构，通过 IP 代理池、请求头随机化、动态 Cookie 管理等技术手段确保数据采集的稳定性和合规性。

在数据融合策略上，系统建立了统一的数据模型和标准化处理流程。首先构建公司-时间维度的主数据模型，以股票代码和报告期作为核心关联键，确保不同来源数据能够准确匹配。然后通过数据清洗、格式转换、异常值处理等步骤，将多源数据统一转换为结构化格式。最后建立数据质量监控体系，对数据完整性、一致性、准确性进行持续评估，为后续分析提供可靠的数据基础。




图 3-1 采集流程图

3.1.2 数据预处理与特征工程

数据预处理是确保分析质量的关键环节，系统建立了完整的数据清洗和特征工程流水线。针对 ESG 报告文本数据，预处理流程包括格式转换、文本清洗、分词处理等多个步骤。首先将 PDF 格式的 ESG 报告转换为纯文本格式，去除页

眉页脚、水印、表格框架等非正文内容。接着进行文本清洗，包括编码统一（转换为 UTF-8 格式）、特殊字符过滤、多余空格的去除等操作。

在分词处理阶段，系统采用 *jieba* 分词工具，并加载自定义的金融领域词典和 ESG 专业术语词典，确保“碳排放”、“公司治理”、“社会责任”等专业词汇能够被准确识别。分词后需要进行去停用词处理，移除“的”、“是”、“在”等无实际意义的虚词，同时保留具有 ESG 语义特征的关键词。在此基础上，进行词性标注和命名实体识别，识别出组织机构、人物、地点、时间等实体信息。

特征工程环节从清洗后的文本中提取具有投资价值的特征指标。系统构建了四个维度的特征体系：首先是漂绿度特征，通过计算 ESG 积极词汇出现频率与 *WindESG* 实际评分的差异来量化；其次是实据性特征，基于时间词、地点词、数量词、行为动词等五类实证要素的出现模式进行评估；第三是全面性特征，通过统计报告对 *GRI*、*SASB* 等国际标准议题的覆盖程度来衡量；最后是可读性特征，从文本长度、句子复杂度、专业术语密度等角度评估报告的可读性。

对于数值型数据，系统进行缺失值处理、异常值检测和数据标准化。采用箱线图法则识别异常值，使用均值填充或预测填充处理缺失数据，最后通过 *Z-score* 标准化消除量纲影响。特征选择阶段采用递归特征消除和相关性分析，筛选出与投资回报显著相关的特征变量，避免维度灾难问题。

3.2 算法模型

3.2.1 基于 *FinBERT* 与自建词典的细粒度 ESG 文本情感分析

本系统采用了一种创新的文本情感分析方法，结合了预训练语言模型 *FinBERT* 和自定义的 ESG 领域词典，实现对 ESG 文本的细粒度情感分析。该方法的核心目标是量化企业在 ESG 报告中表达的“表述积极性”，为后续的漂绿识别提供数据支持。以下是采用 *FinBERT* 与自建词典进行情感分析的实现流程图展示：




图 3-2 情感分析的实现流程图

在自建词典构建方面，系统基于 ESG 领域知识和文本挖掘技术，构建了包含环境、社会和治理三个维度的专业词典。环境维度词典涵盖“碳排放”、“节能减排”、“绿色发展”等关键词；社会维度包括“员工福利”、“社区贡献”、“公益慈善”等术语；治理维度则包含“董事会多样性”、“反腐败”、“信息披露”等词汇。词典构建过程中，我们参考了全球报告倡议组织(GRI)标准、可持续发展会计准则委员会(SASB)标准等国际框架，确保词典的全面性和权威性。下表为自建 ESG 情感词典数据示例：

表 3-1 情感词典示例

维度	正面情绪词	负面情绪词	程度副词	否定词
环境 (E)	绿色发展、节能减排、碳中和	污染、排放、消耗	显著(1.5)、略微(0.7)	未、非、缺乏
社会 (S)	员工福利、社区贡献、公益慈善	事故、纠纷、歧视	高度(2.0)、适度(1.2)	未、非、缺乏
治理 (G)	董事会多样性、信息披露、反腐败	违规、诉讼、内控缺陷	全面(1.8)、部分(0.8)	未、非、缺乏

FinBERT 模型在此基础上进行微调，以适应 ESG 领域的文本特征。微调过程使用大量标注的 ESG 报告文本，训练模型识别文本中的情感倾向和语义强度。与传统的情感分析方法相比，这种结合方法能够更好地理解金融文本的特定表达方式和专业术语的情感色彩。

量化“表述积极性”的具体方法包括以下几个步骤：首先对 ESG 报告进行分词处理，使用 jieba 分词工具加载自定义词典，确保专业术语的准确识别。然后计算文本中积极词汇的密度和强度，其中积极词汇的权重通过 TF-IDF 算法和词汇在 ESG 语境下的情感强度共同确定。接着使用 FinBERT 模型对文本进行深度学习，提取语义特征和情感倾向。最后综合词典匹配和深度学习的结果，生成每个文本的“表述积极性”分数。

这种量化方法的优势在于既考虑了词汇层面的统计特征，又融入了深度学习模型的语义理解能力。例如，对于“公司积极推进碳中和工作，每年减少碳排放 10 万吨”这样的文本，系统不仅会识别出“积极”、“减少”等情感词汇，还能理解“碳中和”、“碳排放”等专业术语在 ESG 语境下的正面意义。

该方法的输出结果包括每个 ESG 报告的总体情感得分，以及环境、社会、治理三个维度的分项得分。这些得分不仅反映了企业 ESG 表述的积极程度，还为后续的漂绿识别提供了重要输入。通过与 WindESG 实际评分对比，系统能够识别出表述积极但实际表现不佳的企业，从而准确量化其漂绿程度。

下表展示了采用本方法对 ESG 文本进行情感分析的部分结果概览：

表 3-1 情感分析部分结果概览

文本内容	情感倾向	得分
公司积极推进碳中和工作，每年减少碳排放 10 万吨	积极	0.87
企业持续完善员工福利体系，大幅提升员工满意度	积极	0.92
公司因环境污染问题受到监管部门处罚	消极	-0.95
董事会多样性不足，缺乏有效的监督机制	消极	-0.78
公司在社区公益方面开展了一些活动	一般	0.35

这种细粒度的情感分析方法为 ESG 投资提供了更加准确和可靠的文本分析工具，帮助投资者更好地评估企业的真实 ESG 表现，避免被表面的积极表述所误导。

3.2.2 基于文本挖掘的 ESG 报告披露特征评估

3.2.2.1 ESG 报告信息披露特征含义

ESG 报告披露特征评估是本系统的核心创新环节，旨在通过文本挖掘技术从 ESG 报告中提取具有投资价值的深度特征。系统主要从漂绿度、实据性、全面性和可读性四个维度对报告进行量化评估，为投资决策提供科学依据。

（一）漂绿度

本研究在 Delmas（2011）理论基础上，将“漂绿”概念拓展至 ESG 领域，将其定义为企业在 ESG 信息披露中的表述积极程度与其真实绩效之间的系统性偏差。为精确识别和量化此种漂绿行为，研究构建了一套系统的测量方法。首先通过开发包含 490 个正向词汇的专业词典，量化企业 ESG 报告中的宣传强度。再采用综合多元数据源与先进技术的 WindESG 评分，作为评估企业真实 ESG 绩效的依据。最后为消除行业差异，对宣传强度和实际绩效分别进行行业内标准化处理。漂绿度的计算即为这两个标准化值的差值，其值越大，表明企业宣传远超其实际表现，漂绿程度越高。该指标有效揭示了企业 ESG 言行不一的落差，为投资者与监管机构提供了识别潜在漂绿行为的量化工具。

鉴于各行业在 ESG 披露特点和绩效表现上存在系统性差异，本研究采用了先进的统计处理方法。首先计算各行业 ESG 宣传强度和实际绩效的均值与标准差，然后对个体企业的原始数据进行标准化处理，最后通过差值计算得到漂绿度指标，其数学表达式为：

$$GREENWASHING_i = \frac{Dis_i - \mu_{industry}}{\sigma_{industry}} - \frac{Per_i - \mu_{industry}}{\sigma_{industry}}$$

其中，公式第一项表示企业的 ESG 表述积极程度相对于同行业公司的标准化度量；公式第二项表示企业的 ESG 实际绩效相对于同行业公司的标准化度量。这一指标帮助识别潜在的“漂绿”行为，为投资者和利益相关方提供更深入的洞察。

（二）实据性

ESG 报告中的“实据性”指信息披露可被验证和证实的程度，直接影响报告的可靠性与可信度。基于 *Schneider* 等人提出的论述理论，完整论述应包含论点、论据和逻辑论证。例如，仅声称“建立开放的公益平台”缺乏说服力，而具体说明“2021 年出资 500 万元设立专项基金”则构成有效论证，显著提升可信度。为量化实据性，本研究借鉴段钊提出的五要素模型，即一个完整事件应包含时间、地点、主语、行为动词和数量词。通过计算语言学方法，识别 ESG 报告中符合至少四个要素的句子比例，作为实据性指标。该指标越高，说明报告中可验证信息越多，信息披露质量越高。具备高实据性的报告能够增强利益相关方的信任，支持其做出更准确的价值判断，从而提升 ESG 信息在投资与监管决策中的实用性。

（三）全面性

ESG 报告的全面性衡量的是信息披露在议题覆盖上的完整程度，反映企业对各方关注点的回应情况。评估主要基于 GRI、SASB、ISSB 等国内外主流 ESG 标准，构建包含环境、社会、治理三大维度及“乡村振兴”等中国特色议题的关键词词典，共计 158 个核心议题。通过计算语言学方法，分析报告内容与词典的匹配度，以覆盖议题的比例作为全面性指标。该指标越高，表明报告内容越完整、披露越充分。全面性评估有助于企业识别信息披露盲区，也为投资者提供了客观、可比的 ESG 质量衡量工具，推动信息披露标准化与决策有效性。

（四）可读性

ESG 报告的可读性是衡量信息传递效率的关键指标。本研究从文本长度、逻辑和难度三个维度构建综合评估体系：文本长度通过总字数、句子数量和平均句长评估阅读负担；文本逻辑考察被动句和转折连词的使用频率，反映表达清晰度；文本难度以次常用字比例衡量理解门槛。采用主成分分析法将六个指标合成为标准化可读性指标，数值越高代表报告越易于阅读和理解。该评估体系为提升 ESG 信息披露效果提供了量化依据，有助于增强报告的信息传递效率。

3.2.2.2ESG 报告信息披露特征评估方法

(一) 相关公告获取

本研究数据来源于证监会指定信息披露网站巨潮资讯网，采集了 2017-2024 年间 A 股上市公司发布的 ESG 类报告。通过构建智能爬取系统，结合股票代码与关键词组合检索，共获取初始样本 11971 份。经数据清洗，包括 OCR 文本识别、剔除图片格式及繁体中文报告后，最终形成包含 1851 家上市公司发布的 11145 份高质量文本的有效样本。近年来，A 股 ESG 报告命名呈现出从“社会责任报告”向标准化“ESG 报告”发展的趋势，反映出信息披露日益规范化的整体走向。

为深入挖掘报告内容特征，研究采用先进的文本可视化技术对报告内容进行多维分析。以浦发银行 2024 年可持续发展报告为例，通过词频分析和语义挖掘生成专业化的词云可视化图谱：



图 3-3 中国银行 2024 年可持续发展报告词云图

该词云图通过关键词频率分析，清晰展示了“平安”“银行”“服务”“金融”等核心业务词汇，同时突出了“客户”“管理”“绿色”“扶贫”等特色 ESG 主题词。通过文本分析可以发现，ESG 报告内容全面涵盖环境保护、社会责任和公司治理等多个维度。这种多维度的内容特征分析为构建 ESG 信息披露评估体系提供了扎实的实证基础，也为企业提升 ESG 报告质量指明了改进方向。

(二) 语料库构建

自然语言处理技术在中文 ESG 文本分析中面临特殊挑战。尽管《人民日报》语料库等通用资源为语言研究提供了基础，但其主要基于新闻和文学作品，难以适应快速发展的 ESG 领域。这些语料库更新滞后，对“碳中和”“绿色金融”等专业术语覆盖不足，限制了分析效果。为此，本研究专门构建了面向 ESG 领域的中文专业语料库。参考《企业 ESG 披露指南》等权威标准，系统整合了环境、社

会、治理维度的专业词汇，并纳入“乡村振兴”等中国特色议题。每个词汇均进行词性标注和语义分类，提升了计算机处理 ESG 报告的准确性。该语料库为 ESG 文本分析提供了专业支持，未来仍需持续更新词汇，以适应 ESG 理念的不断发展，进一步提升分析效率与可靠性。

（三）漂绿度评估

本研究采用系统化的文本分析方法评估企业漂绿程度。首先基于 ESG 研究文献和披露标准，构建了包含 490 个积极词汇的专业词典，涵盖环境、社会与治理三大维度。在文本处理阶段，通过数据清洗、专业分词和词频统计，计算每份报告中积极词汇的占比，以此量化企业的 ESG 宣传强度。同时，本研究选用 WindESG 综合评分作为企业真实 ESG 绩效的衡量指标，该评分整合了企业在环境、社会 and 治理方面的多维表现，具有较高权威性和可比性。为消除行业差异影响，本研究创新性地采用行业相对评价方法：分别对 ESG 宣传强度评分和 WindESG 评分进行行业标准化处理，通过计算两者标准化值的差值得到漂绿度指标。具体计算公式为：

$$\text{漂绿度} = (\text{ESG 宣传强度行业 } Z \text{ 分数}) - (\text{WindESG 评分行业 } Z \text{ 分数})$$

该指标数值越大，表明企业的 ESG 宣传行为与实际表现之间的偏离程度越高，即漂绿现象越明显。这套评估体系为识别企业 ESG 信息披露的真实性提供了量化工具，也为利益相关方进行决策提供了重要参考依据。

（四）实据性评估

本研究基于构建的实据性评估模型，对 ESG 报告文本进行系统分析。首先通过文本预处理清除噪声数据，按句切分并保留完整语义单元，同时处理标题、图表说明等版式元素。研究构建了包含“公司”“本集团”等表述的企业主语词库，统一标注为机构名词以提升主体识别准确性。采用 jieba 工具结合 ESG 语料库进行分词、去停用词和词性标注，结果按句子存储。通过语义角色标注识别时间、地点、行为主体和量化信息等要素，若句子同时包含四类要素则判定为实证语句。最终以实证语句占比生成实据性指标，该流程兼顾科学性与可解释性，为评估 ESG 报告质量提供了可靠依据。

（五）全面性评估

本研究通过整合 GRI、ISO26000 等国际标准与国内相关指南，构建了包含 158 个核心议题的 ESG 评估词典。该词典在涵盖常规 ESG 议题基础上，创新纳入“党的建设”“乡村振兴”等中国特色内容，实现了国际标准与中国实践的结合。采用文本挖掘技术，通过计算报告中涉及议题数与总议题数的比例，生成全面性指标，科学衡量企业在环境、社会及治理维度上的信息披露广度。该方法兼顾国际可比性与本土适用性，为 ESG 研究提供了有效分析工具。

（六）可读性评估

本研究采用主成分分析法构建 ESG 报告可读性评估模型。首先计算六个文本特征指标，随后进行主成分分析。结果显示前三项主成分累计方差贡献率达 91.68%，能够充分代表原始指标信息。研究根据各成分的方差贡献率进行加权计算，生成可读性原始指标。为便于理解，对该指标进行取反和归一化处理，最终得到标准化的可读性评估指标。该指标数值越高，代表报告越易于阅读，既保留了统计特性，又增强了结果的可比性。

表 3-3 各主成分特征值及对应方差贡献率

主成分	特征值	方差贡献率	方差累计贡献率
1	3.6063	0.6011	0.6011
2	1.1329	0.1888	0.7899
3	0.7612	0.1269	0.9168
4	0.2836	0.0472	0.9640
5	0.1740	0.0290	0.9930
6	0.0420	0.0070	1.0000

3.2.2.3 ESG 报告信息披露特征描述性统计

本节对 2017-2024 年 A 股上市公司 ESG 报告的四个信息披露特征漂绿度、实据性、全面性和可读性进行了描述性统计分析，基于 11971 份有效样本数据。分析结果包括各特征的概率分布、均值、标准差及分布特点，并通过表格形式展示极端值案例。以下为详细统计内容。

（一）漂绿度描述性统计




图 3-4 ESG 报告漂绿度概率分布图

漂绿度指标用于衡量企业 ESG 宣传与实际绩效之间的差异。计算结果显示，样本中漂绿度的均值为 0，标准差为 1.43，表明数据围绕均值分布且离散程度较

高。概率分布如图 3.2 所示，分布近似正态，但略有右偏，说明部分企业存在较高的漂绿行为。极端值分析通过表格呈现：

表 3-4 漂绿度最低的 10 份 ESG 报告

年度	公司	漂绿度
2020	三诺公司	-6.9014
2021	京能电力	-6.7154
2022	北辰实业	-6.3058
2022	宁水集团	-5.7880
2021	乐普医疗	-5.6838
2020	农业银行	-5.5075
2020	巨化股份	-5.4943
2020	北辰实业	-5.4827
2021	巨化股份	-5.0590
2022	巨化股份	-5.0116

表 3-5 漂绿度最高的 10 份 ESG 报告

年度	公司	漂绿度
2019	邮储银行	5.6243
2019	泸州老窖	4.4333
2021	南网科技	4.2826
2018	圣农发展	4.0495
2019	圣农发展	3.8875
2022	大东方	3.8036
2019	梦舟股份	3.7984
2019	永安林业	3.7851
2018	长沙银行	3.7598
2022	拓荆科技	3.7485

（二）实据性描述性统计




图 3-5 ESG 报告实据性概率分布图

实据性指标反映 ESG 报告中可验证证据的比例。样本均值为 0.4231，标准差为 0.0869，分布主要集中在 0.35-0.55 之间，表明大多数报告的实据性处于中

等水平，离散程度较低，报告间差异较小。分布形态接近正态，说明企业普遍注重提供事实支撑，但仍有提升空间。

（三）全面性描述性统计




图 3-6 ESG 报告全面性概率分布图

全面性指标评估 ESG 报告议题覆盖的广度。样本均值为 0.2605，标准差为 0.1324，分布主要集中在 0.1-0.3 之间，且呈右偏分布，说明大部分报告的全面性略低于均值，议题覆盖不足。较高的标准差表明不同报告间的全面性差异较大，部分企业披露较全面，而许多企业仍有较大改进余地。

（四）可读性描述性统计




图 3-7 ESG 报告可读性概率分布图

可读性指标衡量 ESG 文本的易读程度。样本均值为 0.1539，标准差为 0.1217，分布集中在 0.1 左右，且呈右偏分布，表明大多数报告的可读性较低，企业倾向于使用专业术语和复杂句式。离散程度适中，反映报告可读性存在一定波动。

3.2.3 基于 ESG 报告信息披露特征的 ESG 投资策划构建

3.2.3.1 企业绩效与 ESG 报告信息披露特征回归分析

为构建有效的 ESG 投资策略，研究通过回归分析方法，考察这些文本特征对企业长期市场价值（托宾 Q ）和短期盈利能力（净资产收益率）的预测能力，从而识别具有可持续发展潜力的优质投资标的，为投资决策提供数据支持。

（一）样本选取及数据来源

本研究采用 CSMAR 和 Wind 数据库获取上市公司财务与 ESG 数据，并基于 Wind 一级行业分类体系进行行业划分。为保障数据质量，对所有连续变量进行了 1%分位的缩尾处理以消除异常值影响。统计分析使用 Stata/SE18 软件完成，通过面板回归、固定效应模型等计量方法，并进行了多重共线性与异方差检验，确保研究结果的稳健性与可靠性。

（二）变量选取

本研究借鉴已有文献，构建了区分长短期影响的企业绩效评估体系。选用下一期的托宾 Q 值衡量长期市场价值，反映成长预期；以下一期净资产收益率(ROE)衡量短期盈利能力。研究以 ESG 报告的四个文本特征为核心自变量：漂绿度、实据性、全面性和可读性。同时控制营业收入增长率、总资产周转率、是否四大审计和独立董事比例等变量。该模型系统分析了 ESG 信息披露对企业绩效的作用机制，为投资决策提供依据。

（三）线性关系检验

在构建线性回归模型时，必须满足因变量与自变量之间存在线性关系的基本假设，这是确保模型准确性和解释力的重要前提。为验证这一假设条件，本研究采用散点图可视化分析方法，对因变量与各自变量之间的关联形态进行直观检验。

针对长期绩效衡量指标，本文绘制了 2017-2024 年间上市公司下一报告期托宾 Q 值与 ESG 报告四个特征变量漂绿度、实据性、全面性、可读性的散点图。可视化分析显示，托宾 Q 值与各 ESG 特征变量之间均呈现出明显的线性关联趋势，数据点分布近似于直线 *pattern*，满足线性回归的模型假设要求。




图 3-8 下一报告期托宾 Q 与 ESG 报告四个特征散点图

在短期绩效方面，本文同样绘制了下一报告期净资产收益率 (ROE) 与四个 ESG 特征变量的散点图 (图 3-9)。分析结果表明， ROE 与各特征变量之间也存在显著的线性关系，数据点的分布规律符合线性模型的构建条件。




图 3-9 下一报告期 ROE 与 ESG 报告四个特征散点图

基于上述可视化分析结果，可以确认 ESG 报告的特征指标与公司长短期绩效指标之间均存在良好的线性关系，满足线性回归模型的基本假设要求，因此适合建立回归模型进行进一步的数量关系分析。这一检验过程为后续的回归分析奠定了方法论基础，确保了研究结论的可靠性。

（四）研究假设

基于现有文献对企业 ESG 表现与绩效关联的研究成果，本研究提出 ESG 报告信息披露质量对企业绩效具有预测作用的核心理念。假设企业 ESG 报告的漂绿程度与未来绩效呈负向关联，而报告的实据性、全面性及可读性特征则与未来绩效呈现正向关系。为验证这一理论框架，研究设立以下两个基本假设：

假设 H1：

探求 ESG 特征与长期绩效的关系，认为 ESG 报告的四个信息披露特征与上市公司下一报告期的托宾 Q 值存在显著相关性。漂绿度指标越低，实据性、全面性和可读性指标越高，则企业长期市场价值表现越佳。

为此构建实证模型 L1，该模型以 $t+1$ 期的托宾 Q 值为因变量，以 t 期的四个 ESG 特征指标为核心自变量，同时引入一系列控制变量并控制年度和行业固定效应。

$$TOBINQ_{i,t+1} = \alpha_0 + \alpha_1 GREENWASHING_{i,t} + \alpha_2 PROOF_{i,t} + \alpha_3 COVER_{i,t} + \alpha_4 READTY_{i,t} + \beta Controls_{i,t} + YEAR_{i,t} + IND_{i,t} + \varepsilon_{i,t}$$

假设 H2：

探求 ESG 特征与短期绩效的关联，提出 ESG 报告的各项特征指标与下一报告期净资产收益率（ROE）存在显著相关。预测漂绿度指标与 ROE 负相关，实据性、全面性和可读性指标与 ROE 正相关。

相应建立实证模型 L2，以 $t+1$ 期 ROE 为因变量， t 期 ESG 特征为自变量，并同样控制相关变量及年度、行业效应。

$$ROE_{i,t+1} = \alpha_0 + \alpha_1 GREENWASHING_{i,t} + \alpha_2 PROOF_{i,t} + \alpha_3 COVER_{i,t} + \alpha_4 READTY_{i,t} + \beta Controls_{i,t} + YEAR_{i,t} + IND_{i,t} + \varepsilon_{i,t}$$

（五）相关性分析

在回归分析前，本研究对各变量进行了相关性检验。结果显示，所有变量之间的皮尔逊相关系数绝对值均低于 0.8 的临界值，未出现高度相关情况，说明模型不存在严重的多重共线性问题。变量间相关性整体处于中低水平，表明模型设定合理，满足回归分析的基本假设，为后续结果的有效性提供了保障。

表 3-6 模型 L1 相关系数表

变量	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
(1)下一报告 期托宾	1.000							
(2)漂绿度	- 0.022*	1.000						
(3)实据性	0.048*	- 0.070*	1.000					
(4)全面性	0.034*	- 0.370*	- 0.186*	1.000				
(5)可读性	0.052*	- 0.435*	- 0.180*	0.600*	1.000			
(6)净资产 收益率	0.258*	- 0.105*	0.039*	0.154*	0.140*	1.000		
(7)营业收 入增长率	0.187*	-0.018	- 0.032*	0.086*	0.054*	0.304*	1.000	
(8)总资产 周转率	- 0.096*	- 0.065*	0.005	0.059*	0.041*	0.228*	0.165*	1.000

* $p < 0.05$

表3-7 模型L2相关系数表

变量	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
(1)下一报告 期ROE	1.000							
(2)漂绿度	- 0.083*	1.000						
(3)实据性	0.049*	- 0.070*	1.000					
(4)全面性	0.141*	- 0.370*	- 0.186*	1.000				
(5)可读性	0.121*	- 0.435*	- 0.180*	0.600*	1.000			
(6)报告期 ROE	0.509*	- 0.105*	0.039*	0.154*	0.140*	1.000		
(7)营业收入 增长率	0.155*	-0.018	- 0.032*	0.086*	0.054*	0.304*	1.000	
(8)总资产周 转率	0.168*	- 0.065*	0.005	0.059*	0.041*	0.228*	0.165*	1.00

* $p < 0.05$

（六）实证研究

基于回归模型的实证结果显示，ESG 报告的信息披露质量与企业长期绩效存在显著关联。漂绿度在 5%水平上显著为负，说明企业“漂绿”行为会损害其长期市场价值；而实据性、全面性和可读性三个指标均在 1%水平上显著为正，表明提升报告的证据支撑、内容广度和阅读便利性有助于增强企业长期绩效。模型拟合优度（ $R^2=0.23$ ）符合社会科学研究的一般标准，结果支持 ESG 报告质量对长期绩效具有显著影响的研究假设。

表 3-8 L1 回归结果

下一报告期托宾 Q	<i>coef</i>	<i>stderr</i>	<i>Z</i>	$P> z $
漂绿度	-0.0294	0.0144	-2.03	0.042
实据性	0.7519	0.2234	3.37	0.001
全面性	0.6910	0.2645	2.61	0.009
可读性	1.7346	0.3070	5.65	0.000
净资产收益率	212520	0.1585	14.20	0.000
营业收入增长率	0.2877	0.0531	5.42	0.000
总资产周转率	-0.1780	0.0446	-3.99	0.000
常数项	0.8621	0.1636	5.27	0.000
年份	控制			
行业	控制			
N	5173			
R^2	0.2315			
$\chi^2(p\text{-value})$	996.12(0.000)			

通过回归分析考察了 ESG 报告特征对企业短期绩效的影响。结果显示，报告全面性与短期绩效在 1%水平上显著正相关，表明拓宽议题覆盖面对短期盈利有积极影响；漂绿度在 10%水平上呈负相关，提示减少虚假宣传有助于提升短期财务表现。而实据性与可读性两项特征未通过显著性检验，说明其对短期绩效影响有限，这可能由于短期业绩更易受市场波动等因素影响。模型拟合优度（ $R^2=0.28$ ）表明解释力良好，结论可靠。

表 3-9 L2 回归结果

下一报告期 ROE	<i>coef</i>	<i>stderr</i> Z	$P> z $
漂绿度	-0.0022	0.0013-1.65	0.095
实据性	0.0246	0.01901.29	0.197
全面性	0.0655	0.02422.70	0.007
可读性	0.0220	0.02810.78	0.435

净资产收益率	0.5400	0.014537.16	0.000
营业收入增长率	0.0063	0.00491.30	0.192
总资产周转率	0.0173	0.00414.22	0.000
常数项	0.0225	0.01501.50	0.133
年份		控制	
行业		控制	
<i>N</i>		5173	
<i>R</i> ²		0.2756	
$\chi^2(p\text{-value})$		1958.44(0.000)	

综合分析表明, *ESG* 报告质量对企业绩效的影响存在明显的时间差异。从长期来看, 四个信息披露特征均显著影响企业市场价值, 降低漂绿度、提升实据性、全面性和可读性, 都有助于增强长期绩效。而在短期方面, 仅全面性和漂绿度对财务表现产生显著影响。这种差异源于 *ESG* 效应的滞后性。*ESG* 因素需要通过改善声誉、增强利益相关方信任等渠道逐步转化为财务成果, 其价值实现需要较长时间。这一发现提示投资者应注重 *ESG* 表现的长期价值, 而非仅关注短期财务回报。

(七) 稳健性检验

为确保研究结论可靠, 本文进行了稳健性检验。通过替换核心变量重新验证: 采用企业价值倍数 (*EV/EBITDA*) 衡量长期绩效, 总资产收益率 (*ROA*) 衡量短期绩效。回归结果显示, *ESG* 报告的四个信息披露特征与替代绩效指标之间的关系方向及显著性均与主检验结果一致, 漂绿度仍为显著负向, 其余三个特征保持显著正向。这表明研究结论具有稳定性, 不受特定指标选择的影响, 进一步增强了实证结果的可信度。

表 3-10 回归结果表

	下一报告期企业价值倍数	下一报告期 <i>ROA</i>
漂绿度	-2.238*	-0.001*
	(1.227)	(0.001)
实据性	33.704*	0.008
	(18.081)	(0.009)
全面性	43.002**	0.038**
	(21.707)	(0.011)
可读性	2.026°	0.017
	(1.124)	(0.019)
净资产收益率	-162.194*	0.268**

营业收入增长率	(13.340)	(0.007)
	5.172	0.002
	(4.832)	(0.002)
总资产周转率	-9.165 ^{**}	0.005 ^{**}
	(3.581)	(0.002)
常数项	31.684 ^{**}	0.012 [*]
	(13.748)	(0.007)
年份	控制	控制
行业	控制	控制
<i>N</i>	5173	5173
<i>R</i> ²	0.1720	0.3167

* $p < 0.1$, ** $p < 0.05$, *** $p < 0.01$

3.2.3.2 基于回归分析结果的 ESG 投资策略

（一）ESG 投资策略的构建与回测

本研究基于 ESG 报告文本分析构建了系统化的投资策略体系。通过提取漂绿度、实据性、全面性和可读性四个核心特征，分别设计了纯 ESG 策略和混合 ESG 策略。纯 ESG 策略包含长期和短期两个组合：长期组合综合四个特征指标，采用动态持有机制；短期组合聚焦漂绿度和全面性，固定持有期一年。混合策略则创新性地将 ESG 因子与传统 *Fama-French* 三因子相结合，先通过 ESG 特征筛选股票池，再运用市值和估值因子选股。为验证策略有效性，研究设置了多维度比较基准，包括传统三因子策略和 *WindESG* 策略。

回测结果显示(2017-2024 年)，混合 ESG 策略表现最优，累计收益达 154.64%，显著优于传统三因子策略（134.89%）和纯 ESG 策略（46.88%），风险调整后收益也得到提升。这一实证结果表明，将 ESG 文本信息融入传统量化模型能有效增强投资绩效，为 ESG 投资实践提供了重要参考。




图 3-10 纯 ESG 投资组合策略回测结果



图 3-11 Fama-French 三因子策略回测结果



图 3-12 混合 ESG 投资策略回测结果



图 3-13 WindESG 策略回测结果

(二) 对回测结果的进一步分析

对纯 ESG 投资策略的回测分析显示，其收益表现具有明显阶段性特征：2021 年 6 月前与市场基准持平，之后持续跑赢并保持稳定超额收益。这一方面得益于近年来 ESG 信息披露质量提升使文本分析更精准，另一方面也体现了 ESG 投资价值实现的长期性。研究采用五年综合数据回归分析，虽牺牲部分实时性，但增强了统计稳健性。策略构建采用指标直接相加的简化方法，平衡了理论精度与实践操作性。本研究验证了 ESG 文本特征与长期绩效的关联性，为 ESG 量化投资提供了方法论基础。

3.2.4 基于机器学习的 ESG 投资策略优化

3.2.4.1 策略优化思路

本研究在传统文本特征分析基础上，引入机器学习方法对 ESG 投资策略进行优化。通过 *TF-IDF* 算法从 2017–2024 年 ESG 报告中提取 2000 余个关键词构建特征向量，利用 *CatBoost* 模型预测企业下期 ROE 变化概率。优化后的纯 ESG 策略将原选股标准替换为机器学习预测的 ROE 提升概率前十的股票；混合策略则直接采用预测结果选取前 20 只股票构建 2024 年投资组合。这种动态预测方法在保留 ESG 核心价值的同时，增强了业绩预测的准确性，为量化投资提供了新的技术路径。

3.2.4.2 特征工程

在构建 ESG 报告分析模型的过程中，首先需要对报告文本内容进行向量化表示，以将非结构化的文字信息转化为可供计算处理的特征形式。随后，依据上市公司的行业属性、企业规模以及经营风格等关键维度对其进行分类编码，从而将不同公司的 ESG 报告纳入统一的表征体系。在此过程中，还将对原始特征进行筛选与优化，剔除冗余或低贡献度的信息，以提升数据质量，确保模型在训练与推理阶段兼具较高的准确性和运行效率。最终，不同企业的 ESG 报告可通过一个结构完整、维度统一的向量空间进行表达和比较。

（一）ESG 报告文本特征提取

本研究基于上市公司 ROE 的正态分布特征，以 12.69% 和 3.44% 为分位点，将企业按盈利能力划分为三个等级：大于 12.69% 为优秀，3.44%–12.69% 为一般，低于 3.44% 为较弱。通过将每份 ESG 报告与下一期 ROE 等级对应，完成训练数据的标注，为后续机器学习建模提供基础。

在文本特征提取阶段，采用 *TF-IDF*（词频-逆文档频率）算法量化关键词的重要性。该算法通过统计词语在特定文本中的出现频率与其在整体语料中的分布情况，计算权重值。具体计算公式如下：

$$TF-IDF = \frac{\text{文本}j\text{中词出现的次数}}{\text{文本}j\text{的总词数}} \times \log \frac{\text{全部文本的个数}}{1 + \text{包含词的文本个数}}$$

对每个经营等级下的 ESG 报告分别计算词语的 *TF-IDF* 值，初步选取各等级下 *TF-IDF* 最高的 1000 个词语（共计 3000 个）。为避免高维矩阵导致的稀疏性问题，结合语义分析人工筛选出 2000 个关键词构成特征词库，如“产品安全”

“产假”等具有业务相关性的术语。最终构建的 *TF-IDF* 矩阵中，每行代表一份 ESG 报告，每列代表一个关键词的权重值，示例如下：

表 3-11 TF-IDF 矩阵示例图

报告编号	产假	产品安全	产品开发	产品品质	产品认证	产品设计
688266_2021	0	0.000209	0	0	0	0
002517_2018	0.000808	0	0	0	0	0
600733_2019	0	0.000120	0.000203	0.000216	0	0
000793_2019	0	0	0	0.000153	0.000266	0.000364
603188_2021	0	0	0	0.000365	0	0
600661_2020	0	0	0	0	0	0
002548_2020	0.000556	0	0	0.000542	0	0

（二）分类特征转换

本研究为提升预测精度，建立了结合行业、市值与投资风格的多维上市公司分类体系。按流通市值将公司分为大盘（前 70%）、中盘（70%-90%）和小盘股（后 10%），同时依据市盈率划分为价值型、均衡型与成长型，形成九大细分类别。采用独热编码技术将分类特征转化为二值变量输入模型，既消除类别间的虚假排序，又完整保留了分类信息。该体系有效捕捉了行业周期、规模效应和风格因子对企业绩效的影响，为精准分析 ESG 文本与财务表现的关联奠定了坚实基础。

表 3-12 行业分类特征独热编码示例

报告编号	材料	电信服务	房地产	工业	公用事业	金融	可选消费	能源	日常消费	信息技术	医疗保健
688266_2021	0	0	0	0	0	0	0	0	0	0	1
002517_2018	0	0	0	0	0	0	0	0	0	1	0
600733_2019	0	0	0	0	0	0	1	0	0	0	0
000793_2019	0	0	0	0	0	0	1	0	0	0	0
603188_2021	1	0	0	0	0	0	0	0	0	0	0
600661_2020	0	0	0	0	0	0	1	0	0	0	0
002548_2020	0	0	0	0	0	0	0	0	1	0	0
002786_2019	0	0	0	1	0	0	0	0	0	0	0

表 3-13 规模风格分类特征独热编码示例

报告编号	大盘价值型	大盘均衡性	大盘成长型	中盘价值型	中盘均衡型	中盘成长型	小盘价值型	小盘均衡型	小盘成长型
688266_2021	0	0	0	0	0	0	0	0	1

002517_2018	0	0	0	0	0	0	0	1	0
600733_2019	0	0	0	0	0	0	0	0	1
000793_2019	0	0	0	0	0	0	0	1	0
603188_2021	0	0	0	0	0	0	0	0	
600661_2020	0	0	0	0	0	0	0	0	1
002548_2020	0	0	0	0	0	0	0	1	0
002786_2019	0	0	0	0	0	0	0	0	1

（三）模型特征选择

本研究构建综合性预测模型，以上市公司下一期 *ROE* 是否提升为预测目标。模型整合行业特征、规模风格特征和 *ESG* 文本信息，共生成 2025 个特征变量。为应对高维问题，采用信息增益算法进行特征筛选，该算法通过计算特征对类别判断的不确定性减少程度来评估特征重要性。通过保留信息增益最大的 250 个特征，实现了有效的降维处理。信息增益通过衡量特征对类别不确定性的减少程度来评估特征重要性，其数学表达式为：

$$IG(Y / X) = H(Y) - H(Y / X)$$

其中 $H(Y)$ 表示类别 Y 的熵， $H(Y|X)$ 表示在已知特征 X 条件下 Y 的条件熵。信息增益值越大，表明该特征对预测 *ROE* 变化的贡献度越高。

特征筛选结果显示，信息增益排名前十的特征中，“庆祝”等文本特征、漂绿度指标及公司规模风格特征均具有较高预测价值。研究保留信息增益最大的 250 个特征进行降维，在保持模型预测能力的同时提升计算效率，为机器学习预测奠定基础。这表明 *ESG* 文本内容与公司特征都是预测企业绩效的有效信息源。

表 3-14 信息增益最大的前 10 个特征

特征	信息增益
<i>ROE</i>	5.05
庆祝	0.61
小盘均衡型	0.59
战略委员会	0.58
长效机制	0.55
节省	0.53
生育	0.53
漂绿度	0.51
创新	0.50
大盘价值型	0.50

在特征筛选中，共有 411 个特征具备有效信息增益，其中前 250 个特征可解释 80% 的信息增益，因此被选为最终模型输入。模型输入变量(X)包括当期 ROE 、四个 ESG 文本特征、行业与规模风格分类变量，以及 225 个关键词的 $TF-IDF$ 数值；输出变量 (Y) 为二元指标，反映下一期 ROE 是否提升（1 表示上升，0 表示下降）。

3.2.4.3 数据建模

本研究将企业绩效预测构建为二分类问题，采用四种集成学习算法（随机森林、 $AdaBoost$ 、 $XGBoost$ 和 $CatBoost$ ）进行对比分析。通过十折交叉验证，综合运用准确率、精确率、召回率和 $F1$ 分数等指标评估模型性能，最终选取最优模型用于 ESG 投资策略优化，确保预测结果的可靠性。

（一）模型评估指标

混淆矩阵是评估二分类模型性能的核心工具，它通过四个基本类别展示预测结果与真实情况的对应关系：真正例表示模型正确预测的正例，假正例表示模型错误预测的正例，真反例表示模型正确预测的反例，假反例表示模型错误预测的反例。基于这四个类别可以计算出准确率、精确率、召回率和 $F1$ 分数等重要评估指标。

在实际应用场景中不同类别的误判代价往往存在显著差异。例如在医疗诊断领域，减少假反例避免漏诊患者至关重要；而在金融风控场景中，准确识别真正例即欺诈交易则更为关键。因此模型优化需要结合具体业务需求有针对性地选择评估指标，不能单纯追求整体准确率。二分类模型的混淆矩阵如下表所示。

表3-15 混淆矩阵

预测值\真实值	正面	负面
正面	真正类(TP)	假负类(FN)
负面	假正类(FP)	假正类(TN)

在评估分类模型性能时，通常采用准确率、精确率、召回率以及 $F1$ 分数等指标。准确率 ($Accuracy$) 衡量的是模型正确分类的样本占总样本的比例，计算公式如下：

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

精确率 ($Precision$) 关注模型预测为正类的样本中有多少是真正的正类，其计算方式为：

$$Precision = \frac{TP}{TP + FP}$$

召回率（*Recall*）则反映所有实际为正类的样本中被模型正确预测出来的比例，计算公式为：

$$Recall = \frac{TP}{TP + FN}$$

精确率与召回率通常存在权衡关系，为综合考察两者性能，可使用 *F1* 分数（*F1-Score*），即精确率和召回率的调和平均数，其表达式为：

$$F_1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

（二）模型选择与优化

本研究采用四种主流集成学习模型——随机森林、*AdaBoost*、*XGBoost* 和 *CatBoost*，对 *ESG* 报告数据进行深度挖掘，旨在预测上市公司未来净资产收益率（*ROE*）的提升趋势。模型训练使用 2018-2021 年期间的 *ESG* 报告数据作为训练集，并以 2017 年的数据作为测试集进行验证。通过准确性（*Accuracy*）和正负样本加权平均 *F1* 分数两个核心指标对模型性能进行系统评估。

实证结果表明，*CatBoost* 模型在两项评估指标上均表现最优，准确率和 *F1* 分数均达到 0.65，展现出最佳的预测性能。相比之下，随机森林模型的准确率为 0.57，*AdaBoost* 和 *XGBoost* 模型的准确率分别为 0.60 和 0.61。这一比较突显了 *CatBoost* 算法在处理结构化数据和类别特征方面的优势。

表 3-16 模型评估结果对比

模型名称	准确率(<i>Accuracy</i>)	正负样本加权平均 <i>F1</i> 分数
随机森林	0.57	0.56
<i>AdaBoost</i>	0.60	0.61
<i>XGBoost</i>	0.61	0.61
<i>CatBoost</i>	0.65	0.65

基于投资实践需求进一步优化模型预测重点。从投资者角度出发，在实际应用自下而上投资策略时，关键目标是准确识别那些未来 *ROE* 确实会提升的上市公司，而非追求覆盖所有可能提升的案例。因此，模型优化的核心方向调整为提高对正类样本的预测精确率。

经过多轮参数调优，*CatBoost* 模型在保持较强泛化能力的同时，对正类样本的预测精确率从 0.71 显著提升至 0.79。这意味着在模型预测为“*ROE* 将提升”的样本中，有 79% 的概率确实会发生 *ROE* 提升，从而为股价上涨提供基本面支撑。尽管整体准确率从 0.65 适度调整至 0.59，但这种优化方向更符合实际投资决策的需求，为后续 *ESG* 投资策略的优化奠定了可靠基础。

3.2.4.4ESG 投资策略优化与回测

本研究基于 *CatBoost* 机器学习模型对 ESG 报告进行深度分析，提升了投资策略的绩效表现。利用优化后的 *CatBoost* 模型对 2024 年 ESG 报告测试集进行预测，模型能够输出每家公司下一报告期净资产收益率（ROE）提升的概率值。通过筛选概率最高的上市公司，对原有的 ESG 投资策略进行针对性优化。

在策略调整方面，针对纯 ESG 投资组合，选取模型预测中 ROE 提升概率排名前 10 的上市公司，替代原策略中 2024 年期（2024 年 5 月 1 日至 2024 年 12 月 31 日）短期持有的股票组合。回测结果显示，优化后的策略收益从原有的 46.88% 上升至 51.45%，增幅约 5 个百分点。同时，风险调整后收益指标夏普比率和超额收益指标 *Alpha* 均有所改善，表明优化措施有效提升了策略的整体表现。

以下为模型预测 ROE 提升概率最高的 10 家公司列表：

表 3-17 模型预测 ROE 提高概率最大的 10 家公司

证券代码	证券简称	ROE 提高预测概率
601127	赛力斯	0.91
600679	上海凤凰	0.90
600418	江淮汽车	0.90
002097	山河智能	0.88
600011	华能国际	0.87
600257	大湖股份	0.86
002205	国统股份	0.85
000698	沈阳化工	0.84
603717	天域生态	0.84
002037	保利联合	0.83

这一优化过程验证了机器学习模型在 ESG 投资决策中的实用价值，通过量化分析 ESG 报告文本信息，能够更精准地识别潜在的价值提升机会，为投资组合的持续优化提供数据支持。




图 3-14 优化后纯 ESG 投资组合策略回测结果对比

本研究对混合 ESG 投资策略进行了重要优化，采用 CatBoost 机器学习模型预测上市公司 ROE 提升概率，并选取概率排名前 20 的标的构建 2025 年投资组合。回测结果显示，优化后策略年化收益率从 154.64% 提升至 167.51%，夏普比率和 Alpha 值也同步改善。这表明“ESG+AI”的研究方法能有效提升投资绩效，为 ESG 投资策略优化提供了新的技术路径。




图 3-15 优化后混合 ESG 投资组合策略回测结果对比

本研究创新性地将 CatBoost 机器学习模型应用于 ESG 投资策略优化。通过该模型预测上市公司 ROE 提升概率，并选取概率最高的标的替换原投资组合中的持仓股票。实证结果显示，优化后的策略在 2023 年实现了显著超额收益，夏普比率和 Alpha 值同步改善，验证了“ESG 分析+机器学习预测”新范式的有效性。该方法为 ESG 投资提供了可复制的技术路径，展现了人工智能在可持续金融领域的应用潜力。

3.3 数据可视化大屏设计

3.3.1 项目介绍

智策未来-ESG 投资策略可视化分析平台是一个面向金融机构、投资研究团队及监管部门的综合性数据可视化系统。系统基于多源异构数据（包括金融文本、市场数据、舆情信息等），通过自然语言处理、机器学习与动态策略回测，实现对 ESG 投资策略的全生命周期监控与优化。平台核心目标是解决传统 ESG 评级的信息滞后性与“漂绿”问题，通过动态可视化工具帮助用户实时追踪企业 ESG 表现、策略绩效及风险暴露，辅助投资决策与风险管理。

系统名称“智策未来”寓意数据智能驱动投资策略，强调通过 AI 技术挖掘 ESG 因子的长期价值。平台整合了文本特征分析（漂绿度、实据性、全面性、可读性）、多模态因子集成学习、强化学习动态调仓等核心技术，并通过交互式大屏提供直观的数据洞察。系统设计注重实时性、可扩展性与用户友好性，支持多

维度数据下钻、自定义预警规则和策略回测对比，旨在成为 ESG 投资领域的智能决策中枢。




图 3-16 技术路线图

3.3.2 可视化系统设计

为了实现“智策未来-ESG 投资策略可视化分析平台”的目标，系统采用前后端分离的微服务架构，这种设计显著提升了扩展性、维护性和性能。前端专注于用户交互和可视化呈现，通过现代框架构建动态界面；后端处理数据采集、存储和复杂计算，提供稳定的 API 服务；部署层面确保系统高可用性和实时性。整体架构支持多源数据集成、实时分析和智能预警，满足 ESG 投资决策的高频需求。

（一）前端设计


前端基于 Vue3 框架和 TypeScript 开发，结合 ECharts5 和 AntVG6 可视化库，构建响应式且交互丰富的用户界面。Vue 的组件化机制允许将功能模块（如策略回测面板、舆情监控图表）封装为独立组件，通过数据绑定实现动态更新。ECharts 提供折线图、雷达图、热力图等多样化图表，用于展示收益曲线、ESG 特征分布和地域舆情热度；AntVG6 处理关系网络图，可视化用户影响力拓扑。前端集成 WebSocket 客户端，支持实时接收后端数据推送，确保舆情预警和策略绩效指标每秒更新。界面采用 ElementPlusUI 库提供统一的设计语言，包括过滤器、下拉菜单和仪表盘控件，用户可自定义视图和下钻分析。响应式布局适配桌面、平板和移动设备，提升跨平台体验。以下为前端设计图：



3-17 前端设计图

(二) 后端设计

后端采用 *SpringBoot2.7* 框架，提供 *RESTfulAPI* 和 *GraphQL* 接口，处理数据流水线和业务逻辑。数据采集模块通过爬虫技术从 *WindAPI*、巨潮资讯网和社交媒体平台获取 *ESG* 报告和市场数据，经 *ApacheFlink* 流处理引擎进行实时清洗和特征计算（如漂绿度、实据性）。机器学习模型（如 *CatBoost* 和梯度提升树）通过 *TensorFlowServing* 部署，用于因子重要性分析和情感评分。数据库层使用 *PostgreSQL* 存储结构化数据，*Elasticsearch* 支持全文检索，*Redis* 缓存热点数据以降低延迟。后端服务通过 *Kafka* 消息队列解耦数据处理流程，确保高并发场景下的稳定性。*API* 设计包括策略回测、舆情分析、实时监控等模块，返回 *JSON* 数据供前端渲染。以下为后端设计图：



3-18 后端设计图

(三) 部署设计

部署策略基于 *Docker* 容器化和 *Nginx* 反向代理，实现环境一致性和高性能访问。前端静态资源（*Vue* 打包后的 *HTML*、*CSS*、*JavaScript* 文件）由 *Nginx* 托管，配置 *SSL/TLS* 证书启用 *HTTPS* 加密，并通过负载均衡分发请求。后端服务封装为 *Docker* 容器，使用 *DockerCompose* 编排 *SpringBoot* 应用、数据库和中间件（如 *Kafka*、*Redis*），部署于云服务器支持弹性伸缩。监控工具（如 *Prometheus* 和 *Grafana*）跟踪系统性能和故障预警，确保可用性。域名解析通过 *Nginx* 配置映射到服务器 *IP*，用户可通过统一域名访问系统。实时数据流水线采用微服务架构，各模块独立部署，支持横向扩展以应对数据量增长。

3.3.3 可视化系统界面介绍

(一) 首页




图 3-19 系统登录页面

系统首页设计简洁专业，提供安全的用户登录入口。用户可通过输入账号和密码验证身份，成功登录后即可进入系统主界面，访问完整的 ESG 投资分析功能。

（二）仪表盘板块



图 3-20 仪表盘板块页面

仪表盘作为系统核心界面，集成多维度数据可视化组件，动态展示投资组合表现、ESG 评分分布、市场风险指标等关键信息。用户可通过交互式图表实时监控策略绩效，支持自定义时间范围和指标筛选，提供全面的投资决策看板。

（三）策略分析板块




图 3-21 策略分析板块页面

该板块深度整合文本分析结果与市场数据，提供策略回测、绩效归因和因子分析功能。用户可对比纯 ESG 策略、混合策略及基准策略的表现，通过动态曲线图查看收益走势、夏普比率和最大回撤等指标，支持参数调整和模拟测试。

（四）ESG 评估板块



图 3-22 ESG 评估板块页面

基于文本挖掘技术，该板块提供企业 ESG 特征量化评估，包括漂绿度、实据性、全面性和可读性四大维度。用户可通过雷达图、柱状图和多维度表格查看企业 ESG 评分详情，支持行业对比和历史趋势分析，精准识别高质量披露企业。

（五）舆论监测板块



图 3-23 舆论监测板块页面

实时追踪 ESG 相关舆情动态，整合新闻、社交媒体和公告等多源文本数据。通过情感分析热力图和时间序列曲线，可视化市场情绪变化和事件影响强度，支持自定义预警规则和风险推送，助力用户及时应对潜在危机。

（六）数据报告板块



图 3-24 数据报告板块页面

提供结构化数据导出和定制化报告生成功能。用户可基于分析结果自动生成 *PDF* 或 *Excel* 格式的深度研究报告，涵盖 *ESG* 绩效评估、策略回测总结和舆情监测摘要，支持一键分享和协作编辑，提升投资研究效率。

系统界面采用响应式设计，兼容多终端设备，结合 *Vue.js* 框架与 *ECharts* 可视化库，确保用户交互流畅且数据呈现清晰。各板块支持数据下钻和关联分析，满足专业机构投资者对 *ESG* 投资的深度洞察需求。

3.4 实现过程

智策未来-*ESG* 投资策略可视化分析平台由数据采集系统、*ESG* 分析引擎和可视化展示系统三部分组成。首先由数据采集系统获取多源 *ESG* 相关数据，数据来源于上市公司披露的 *ESG* 报告、企业社会责任报告、年度财务报告等公开信息，同时整合舆情数据平台、新闻媒体和企业公告等非结构化数据源。采集的数据包含企业环境表现、社会责任、公司治理等结构化指标，以及文本描述、管理层讨论等非结构化内容。采集的原始数据经过数据清洗、标准化和特征工程处理，分别进行 *ESG* 评分计算、风险识别、趋势分析和文本特征挖掘。通过自然语言处理技术分析企业 *ESG* 报告的文本特征，包括漂绿度识别、实据性评估、全面性分析和可读性评价，同时结合定量指标构建多维度 *ESG* 评估体系。最后将基础数据、分析结果和投资洞察以交互式图表形式在可视化大屏展示，用户可

根据投资需求自由查看行业 ESG 风险趋势、企业 ESG 评分排名、特定企业历史表现对比等深度分析内容。系统支持多维度数据下钻、自定义筛选条件和个性化报表生成，为 ESG 投资决策提供全面数据支持。

（系统架构设计、算法实现细节请参阅附件中的技术文档）

4.应用价值

4.1 经济效益分析

此项策略优化的经济效益是直接且显著的，主要体现在投资绩效的提升、风险管理能力的增强以及运营效率的优化上。

4.1.1 提升投资组合的绝对收益与风险调整后收益

挖掘前瞻性：细粒度文本分析能够捕捉到评级机构尚未反映的 ESG 信号。例如，通过分析电话会议中管理层对碳中和技术路径的详细阐述，可以比市场更早判断其技术可行性与成本优势，从而在正面影响股价前进行布局。同样，对负面新闻（如劳资纠纷、环保诉讼）的语义分析和情感计算，可以预警潜在风险，实现提前规避。

降低风险，识别真正领先者：通过自然语言处理技术，可以量化企业 ESG 陈述的实质性和具体性。一个充斥着空洞口号的公司，与一个详细披露其碳减排路线图和供应商行为准则的公司，其 ESG 质量高下立判。这种深度鉴别能力有助于投资者避开 ESG 价值陷阱，投资于真正具备可持续发展能力的公司，从而获得长期超额回报。

动态资产再平衡：结合市场数据，策略可以实时响应。例如，当某公司发布一项重大的绿色技术突破（文本信号），同时伴随异常放量上涨（市场信号），系统可以即时提示增持机会。反之，当负面 ESG 事件出现且引发股价异动时，系统能辅助决策是“市场过度反应”带来的抄底机会，还是基本面恶化的开始，从而实现更精准的择时。

4.1.2 增强风险管理与回撤控制

预警“尾部风险”：许多重大的股价暴跌源于 ESG 相关的黑天鹅事件（如重大环境污染、数据泄露、贪污丑闻）。细粒度文本分析可以在事件全面爆发前，从监管问询、地方媒体报道、员工匿名爆料等碎片化信息中识别出风险积聚的早期信号，使投资组合能够提前降低风险暴露，有效控制最大回撤。

降低合规与声誉风险：对于受严格 ESG 监管约束的机构投资者（如养老金、主权基金）而言，该策略能确保其投资组合更符合监管要求，避免因投资于高 ESG 风险公司而带来的罚款或声誉损失。

4.1.3 优化投资决策流程与效率

实现规模化与自动化分析：传统 ESG 尽调高度依赖人工，成本高、覆盖面窄。该策略利用 AI 技术，可以实现对数千家上市公司海量非结构化文本的自动化处理，将分析师从繁琐的信息搜集中解放出来，专注于更高价值的决策判断。

创造可复用的数据资产：构建的细粒度 ESG 数据库本身就成为机构的核心竞争优势。这套数据资产不仅可以用于直接投资，还可以用于开发 ESG 指数、衍生品，或为投行、研究部门提供增值服务，开辟新的收入渠道。

4.2 社会价值分析

此项策略优化的社会价值深远，它通过资本市场的价格发现和资源配置功能，引导经济资源向更可持续、更负责任的领域集中，从而产生强大的正外部性。

4.2.1 精准引导资本流向，赋能实体经济转型

奖励言行一致的企业：该策略能够识别并奖励那些在 ESG 实践中“说到做到”的企业。当资本市场给予这些企业更高的估值和更低的融资成本时，就形成了一个强大的正向激励，鼓励更多企业进行真实的 ESG 投入和创新，而不是仅仅进行公关宣传。

支持实质性议题创新：策略可以聚焦于与行业最相关的“实质性 ESG 议题”（如科技公司的数据安全、制造业的循环经济）。这使得资本能够更精准地支持那些在关键领域取得突破的企业，例如，投资于研发新型降碳技术的化工企业，或致力于提升供应链透明度的消费品公司，直接推动相关产业的技术进步和模式变革。

4.2.2 提升市场信息效率，强化社会监督

弥补官方评级的信息缺口：它为市场提供了更丰富、更及时的 ESG 信息维度，打破了少数评级机构的信息垄断，促进了信息的多元化和市场竞争，使整个市场对企业 ESG 表现的定价更为有效。

构建无处不在的“监督网络”：通过自动化地扫描和分析全球媒体、社区反馈等公开信息，该策略实质上构建了一个强大的社会监督机制。企业的任何不当

行为都更难被掩盖，从而迫使企业管理者更加注重其经营活动对社会和环境的长远影响，履行真正的企业公民责任。

4.2.3 推动 ESG 理念的深化与普及

从理念到量化标准：它将模糊的 ESG 理念转化为清晰的数据指标和投资逻辑，使更多以财务回报为首要目标的传统投资者能够理解并接受 ESG 投资，极大地扩展了可持续金融的参与群体。

促进长期主义投资文化：通过实证数据证明 ESG 因素与长期财务绩效的正相关关系，该策略有助于在整个资本市场培育和巩固长期主义、价值投资的理念，引导资本关注超越短期财报的长期价值创造，这对于应对气候变化、社会不平等全球性挑战至关重要。

5. 系统优化与展望

5.1 当前局限性

尽管智策未来-ESG 投资策略分析平台在 ESG 数据分析方面取得了显著成果，但系统仍存在以下几个方面的局限性：在数据覆盖范围方面，系统目前主要聚焦于 A 股和港股市场的上市公司 ESG 数据，对债券市场、非上市公司以及国际资本市场的覆盖相对有限。这种局限性使得分析视角主要集中于权益类资产，难以全面反映整体资本市场的 ESG 表现。特别是在新兴行业和中小型企业方面，数据采集的深度和广度仍有待加强。在数据分析维度上，当前系统主要采用基于规则和传统机器学习的分析方法，虽然能够有效处理结构化数据和基础文本分析，但在处理复杂的 ESG 文本语义理解和多维度因子关联分析时仍存在优化空间。例如，对于 ESG 报告中隐含的深层语义信息和行业特定术语的理解能力有待提升。

实时性方面，系统目前采用 T+1 的数据更新频率，对于突发性 ESG 事件的响应存在一定滞后。这种延迟可能影响对市场突发风险的及时预警和快速响应能力，特别是在处理重大环境事故、公司治理危机等紧急事件时，需要进一步提升数据采集和处理的时效性。在交互体验层面，虽然系统提供了丰富的可视化功能，但在个性化定制和智能推荐方面仍有提升空间。用户无法根据自身投资偏好和分析习惯深度定制界面布局和内容展示方式，协同分析功能也相对基础，难以支持复杂的团队协作需求。技术架构方面，随着数据量的持续增长和分析复杂度的提

升，当前系统在计算性能和扩展性方面面临挑战。特别是在处理大规模文本数据和非结构化信息时，计算效率和处理能力需要进一步优化。

5.2 未来展望

面向未来，智策未来平台将持续进行技术迭代和功能拓展，致力于打造更加智能、全面的 ESG 投资分析生态系统。在数据扩展方面，计划纳入更多资本市场的 ESG 数据，包括债券市场、私募股权和国际主要交易所的上市公司数据。同时将加强对非财务信息的结构化处理能力，拓展数据源的多样性和覆盖范围，建立全球化的 ESG 数据网络。

在分析技术层面，将引入深度学习方法，采用基于 *Transformer* 架构的预训练模型，提升对 ESG 报告深层次语义的理解能力。重点加强多模态数据融合分析，整合文本、数值、网络关系和图像等多类信息，构建更加精准的 ESG 评估模型。同时将开发行业特定的分析模型，针对不同行业的特点建立定制化的 ESG 评估体系。实时性提升方面，将构建流式计算架构，实现 ESG 数据的实时采集和处理。通过建立 ESG 事件快速响应机制，结合自然语言处理技术实现对 ESG 相关新闻、公告和社交媒体的实时监控，将数据更新频率提升至近实时水平，增强对市场突发事件的响应能力。在用户体验优化方面，将引入用户行为分析技术，基于用户的使用习惯和关注点，提供个性化的界面布局和内容推荐。计划开发智能助手功能，通过自然语言交互支持用户的数据查询和分析需求。同时将增强协同分析功能，支持团队间的实时协作与知识共享，提供版本管理和注释讨论等高级功能。技术架构优化方面，将采用分布式计算框架，提升系统的计算性能和扩展性。通过引入微服务架构，增强系统的灵活性和可维护性，同时建立更加完善的数据安全和隐私保护机制。

生态系统建设方面，计划开放 API 接口，支持第三方开发者和研究机构的接入与合作。同时将建立 ESG 知识图谱，整合产业链、供应链和资本链的多维关系，提供更加深入的洞察分析能力。通过这些持续的技术创新和功能拓展，智策未来平台将不断提升其在 ESG 投资领域的分析能力和服务水平，为推动负责任投资和可持续发展做出更大贡献，致力于成为 ESG 投资领域的一流分析工具和决策支持平台。

参考文献

- [1]祝清麟,梁斌,徐睿峰,等.结合金融领域情感词典和注意力机制的细粒度情感分析[J].中文信息学报,2022,36(08):109-117.
- [2]朱家成.基于特征融合的互联网金融领域命名实体识别算法研究[D].西安,2022.
- [3]徐军.面向金融信息检索的体裁分类与情感分析技术研究[D].哈尔滨,2011.
- [4]刘新春,宁若瑄.制药企业 ESG 表现的驱动因素剖析——基于多层次视角理论的动态 QCA 方法[J/OL].财会月刊,1-7[2025-09-30].
- [5]许志勇,艾万谋,甘敏,等.数据资产与企业风险承担:促进还是抑制? [J/OL].系统工程理论与实践,1-30[2025-09-30].
- [6]唐亮,杨国玉.数据资产如何赋能企业 ESG 表现[J/OL].软科学,1-12[2025-09-30].
- [7]黄筱.重污染企业 ESG 表现与融资约束[J].合作经济与科技,2025,(19):149-151.
- [8]马萌瑶.中部地区 ESG 发展现状及建议[J].合作经济与科技,2025,(19):43-45.
- [9]宋灿,王晶晶,岳中刚.企业 ESG 表现与供应链空间扩张[J/OL].商业研究,1-12[2025-09-30].
- [10]王利政,陈慧.践行“国家能源·责任动力”谱写煤炭行业可持续发展新篇章[J].中国煤炭工业,2025,(10):6-8.
- [11]Liu M ,Zuo C.Study on the Nonlinear Impact of Corporate ESG Ratings on Debt Financing Costs[J].Forum on Research and Innovation Management,2025,3(10):
- [12]Du L ,Lu N .Do ESG incidents matter for corporate cost of debt? Evidence from China[J].Finance Research Letters,2025,86(PB):108459-108459.
- [13]Wang C ,Li J .The impact of ESG reporting audits on investor decisions: evidence from the capital market[J].Finance Research Letters,2025,86(PB):108449-108449.
- [14]Yang Y ,Lyu J ,Wei Y .Big data applications, technological empowerment, and corporate ESG performance[J].Finance Research Letters,2025,86(PB):108427-108427.
- [15]Cai Y ,Xiao X ,Hu Y .ESG initiatives and investment efficiency in energy industries: The moderating role of regulation[J].Finance Research Letters,2025,86(PB):108371-108371.
- [16]Klimenko M ,Romanyuk K .Investor perception of ESG-linked credit risk during the COVID-19 pandemic for U.S. and European firms[J].Finance Research Letters,2025,86(PB):108464-108464.
- [17]Song Y ,Luo S ,Li A , et al.How ESG performance shapes institutional investor preference? The mediating role of scale efficiency[J].Finance Research Letters,2025,86(PB):108446-108446.
- [18]Dong H ,Wang L ,Wu X , et al.The impact of green innovation network embeddedness on ESG performance in energy enterprises: The mediating role of green dynamic capabilities and the moderating role of organizational agility[J].Journal of Cleaner Production,2025,526146632-146632.
- [19]Dong H ,Wang L ,Wu X ,et al.The impact of green innovation network embeddedness on ESG performance in energy enterprises: The mediating role of green dynamic capabilities and the moderating role of organizational agility[J].Journal of Cleaner Production,2025,526146632-146632.
- [20]Fildisi B ,Vakaj E ,Dridi A , et al.Integrating AI-driven analytics for enhanced ESG mapping: Aligning local and global perspectives[J].Sustainable Futures,2025,10101231-101231.